Universidad San Carlos De Guatemala.

Facultad de Ingeniería.

Ingeniería en Ciencias y Sistemas.

PROYECTO 2.

Procesamiento y Análisis Exploratorio de Datos Masivos en BigQuery

Grupo #20

Estudiante	**Carnet.**
Juan Carlos Maldonado Solorzano.	2012-226-87.
Kimberly Julissa Estupe Chen	201513656

INTRODUCCIÓN

El análisis de grandes volúmenes de datos representa un desafío importante en términos de rendimiento, costo y capacidad de interpretación. En este proyecto se aborda este problema mediante el uso del dataset público **NYC Taxi Trips 2022**, disponible en BigQuery, el cual contiene más de 100 millones de registros de viajes de taxi en la ciudad de Nueva York.

El objetivo principal consiste en diseñar e implementar un proceso completo de análisis exploratorio de datos masivos, utilizando consultas SQL avanzadas, técnicas de optimización como particiones y clustering, y herramientas de visualización. Asimismo, se integran modelos de Machine Learning mediante BigQuery ML para generar predicciones y analizar patrones de comportamiento en los datos.

Este proyecto permite desarrollar competencias en análisis de datos en la nube, optimización de consultas, ingeniería de características y comunicación efectiva de hallazgos a través de visualizaciones.

OBJETIVO GENERAL

Desarrollar un proceso integral de análisis exploratorio de datos masivos utilizando el dataset público de viajes de taxi de Nueva York en BigQuery, aplicando técnicas de transformación, optimización mediante particiones y clustering, y modelos de Machine Learning para identificar patrones relevantes y generar predicciones, comunicando los resultados a través de visualizaciones claras.

OBJETIVOS ESPECÍFICOS

1. Conectarse y explorar el dataset público de BigQuery, identificando su estructura, volumen de datos y variables relevantes para el análisis.

2. Diseñar y ejecutar consultas SQL avanzadas que permitan calcular métricas descriptivas, analizar distribuciones y detectar patrones temporales, geográficos y económicos.

3. Crear tablas derivadas optimizadas mediante la implementación de particiones y clustering, con el fin de mejorar el rendimiento y reducir el costo de procesamiento.

4. Realizar una comparación entre consultas estándar y optimizadas, evidenciando la reducción en el uso de recursos (bytes procesados y tiempo de ejecución).

5.Aplicar técnicas de ingeniería de características para construir un dataset adecuado para modelos de Machine Learning, incluyendo la creación de variables derivadas y limpieza de datos.

6. Entrenar y evaluar al menos dos modelos predictivos en BigQuery ML, uno de clasificación y otro de regresión, utilizando métricas adecuadas para medir su desempeño.

7. Implementar estrategias para prevenir data leakage mediante la correcta división de los datos en conjuntos de entrenamiento, evaluación y predicción.

8. Desarrollar visualizaciones en Looker Studio o Google Sheets que permitan comunicar de manera clara los hallazgos exploratorios y los resultados de los modelos predictivos.

Conexión Al DataSet Publico.

```
-- CONEXIÓN AL DATASET PÚBLICO.

-- Dataset utilizado  bigquery-public-
data.new_york_taxi_trips.tlc_yellow_trips_2022

-- Exploración de datos.
-- Muestra las primeras 10 filas de la tabla para ver cómo son los datos (columnas,
valores, formato, etc.).

SELECT *
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
LIMIT 10;

-- Conteo de registros
-- Cuenta cuántos registros (viajes) hay en toda la tabla.
SELECT COUNT(*) AS total_registros
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`;

-- Revisar estructura
-- Muestra los nombres de las columnas y su tipo de dato (STRING, INTEGER,
TIMESTAMP, etc.).

SELECT column_name, data_type
FROM `bigquery-public-data.new_york_taxi_trips.INFORMATION_SCHEMA.COLUMNS`
WHERE table_name = 'tlc_yellow_trips_2022';
```

Análisis Exploratorio

```sql
-- Ver esquema de la tabla publica.

-- Da más detalle del esquema:
-- Si la columna acepta nulos
-- El orden en que aparece en la tabla

SELECT
  column_name,
  data_type,
  is_nullable,
  ordinal_position
FROM `bigquery-public-data.new_york_taxi_trips.INFORMATION_SCHEMA.COLUMNS`
WHERE table_name = 'tlc_yellow_trips_2022'
ORDER BY ordinal_position;

-- Estadísticas generales

-- Obtiene un resumen general:
-- Total de filas
-- Rango de fechas (inicio y fin de viajes)
-- Distancias mínimas y máximas

SELECT
  COUNT(*) AS total_rows,
  MIN(pickup_datetime) AS min_pickup_datetime,
  MAX(pickup_datetime) AS max_pickup_datetime,
  MIN(dropoff_datetime) AS min_dropoff_datetime,
  MAX(dropoff_datetime) AS max_dropoff_datetime,
  MIN(trip_distance) AS min_trip_distance,
  MAX(trip_distance) AS max_trip_distance
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`;
```

```sql
-- Análisis por mes

-- Agrupa los datos por mes para ver:
-- Cantidad de viajes
-- Promedio de pago total
-- Promedio de distancia

SELECT
  EXTRACT(MONTH FROM pickup_datetime) AS pickup_month,
  COUNT(*) AS trips,
  ROUND(AVG(total_amount), 2) AS avg_total_amount,
  ROUND(AVG(trip_distance), 2) AS avg_trip_distance
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
GROUP BY pickup_month
ORDER BY pickup_month;

-- Análisis por tipo de pago

-- Analiza cómo pagan los clientes:
-- Número de viajes por tipo de pago
-- Promedio de propina
-- Promedio de tarifa

SELECT
  payment_type,
  COUNT(*) AS trips,
  ROUND(AVG(tip_amount), 2) AS avg_tip_amount,
  ROUND(AVG(fare_amount), 2) AS avg_fare_amount
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
GROUP BY payment_type
ORDER BY trips DESC;
```

```sql
-- Análisis por hora del día

-- Muestra el comportamiento según la hora:
-- Cuántos viajes hay por hora
-- Distancia promedio
-- Pago promedio

SELECT
  EXTRACT(HOUR FROM pickup_datetime) AS pickup_hour,
  COUNT(*) AS trips,
  ROUND(AVG(trip_distance), 2) AS avg_trip_distance,
  ROUND(AVG(total_amount), 2) AS avg_total_amount
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
GROUP BY pickup_hour
ORDER BY pickup_hour;

-- Rutas más frecuentes

-- Identifica las rutas más usadas:
-- Origen y destino
-- Número de viajes
-- Ingreso total generado

SELECT
  pickup_location_id,
  dropoff_location_id,
  COUNT(*) AS trips,
  ROUND(SUM(total_amount), 2) AS total_revenue
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
GROUP BY pickup_location_id, dropoff_location_id
ORDER BY trips DESC
LIMIT 20;
```

```sql
-- Análisis exploratorio.

-- Metricas basicas

-- Resume el dataset con indicadores generales:
-- total_viajes: número total de viajes
-- promedio_pago: cuánto se paga en promedio por viaje
-- distancia_promedio: qué tan largos son los viajes en promedio

SELECT
  COUNT(*) AS total_viajes,
  AVG(total_amount) AS promedio_pago,
  AVG(trip_distance) AS distancia_promedio
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`;

-- Analisis temporal (por mes)
-- Muestra cómo se distribuyen los viajes a lo largo del año:
-- Agrupa por mes
-- Cuenta cuántos viajes hay en cada mes
-- Sirve para identificar estacionalidad o meses con mayor demanda

SELECT
  EXTRACT(MONTH FROM pickup_datetime) AS mes,
  COUNT(*) AS viajes
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
GROUP BY mes
ORDER BY mes;


-- Distribucion por pasajeros

-- Analiza cuántos pasajeros van en los viajes:
-- Agrupa por cantidad de pasajeros
-- Cuenta cuántos viajes hay en cada grupo
-- Permite ver si predominan viajes individuales, en pareja, etc.

SELECT passenger_count, COUNT(*) AS total
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
GROUP BY passenger_count
ORDER BY total DESC;
```

```sql
-- Análisis de propinas

-- Evalúa el comportamiento de las propinas:

-- promedio_propina: cuánto dejan en promedio
-- max_propina: la propina más alta registrada
-- Útil para entender hábitos de pago y casos extremos


SELECT
  AVG(tip_amount) AS promedio_propina,
  MAX(tip_amount) AS max_propina
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`;
```

Creación de la tabla DERIVADA (optimización)

Creación del dataset

```sql
-- 1. Crear el dataset
CREATE SCHEMA IF NOT EXISTS `Proyecto2_G20`;
```

Descripción:
Crea un dataset (base de datos lógica en BigQuery) llamado `Proyecto2_G20` si no existe.

Objetivo:
Organizar y almacenar las tablas del proyecto en un espacio propio.

Creación de la tabla optimizada

```sql
-- 2. Tabla optimizada con PARTITION BY y CLUSTER BY
CREATE OR REPLACE TABLE `Proyecto2_G20.taxi_trips_2022_optimized`
PARTITION BY pickup_date
CLUSTER BY vendor_id, pickup_location_id, payment_type
AS
WITH source_data AS (
  SELECT
    vendor_id,    pickup_datetime,    dropoff_datetime,
    DATE(pickup_datetime) AS pickup_date,    passenger_count,    trip_distance,
    rate_code,    store_and_fwd_flag,    pickup_location_id,
    dropoff_location_id,    payment_type,    fare_amount,    extra,    mta_tax,
    tip_amount,    tolls_amount,    imp_surcharge,    airport_fee,    total_amount
  FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
  WHERE DATE(pickup_datetime) BETWEEN '2022-01-01' AND '2022-12-31'
)
SELECT
  vendor_id,
  pickup_datetime,
  dropoff_datetime,
  pickup_date,
  passenger_count,
  trip_distance,
  rate_code,
  store_and_fwd_flag,
  pickup_location_id,
  dropoff_location_id,
  payment_type,
  fare_amount,
  extra,
  mta_tax,
  tip_amount,
  tolls_amount,
  imp_surcharge,
  airport_fee,
  total_amount,
  TIMESTAMP_DIFF(dropoff_datetime, pickup_datetime, MINUTE) AS trip_duration_minutes,
  EXTRACT(HOUR FROM pickup_datetime) AS pickup_hour,
  EXTRACT(DAYOFWEEK FROM pickup_datetime) AS pickup_day_of_week,
  EXTRACT(MONTH FROM pickup_datetime) AS pickup_month,
  -- Propina alta si es >= 20% (clásico)
  IF(SAFE_DIVIDE(tip_amount, NULLIF(fare_amount, 0)) >= 0.20, 1, 0) AS is_high_tip
FROM source_data
WHERE pickup_datetime IS NOT NULL
  AND dropoff_datetime IS NOT NULL
  AND dropoff_datetime >= pickup_datetime
  AND passenger_count BETWEEN 1 AND 6
  AND trip_distance > 0 AND trip_distance <= 100
  AND fare_amount > 0 AND fare_amount <= 500
  AND total_amount > 0;
```

DESCRIPCIÓN DE LA TABLA OPTIMIZADA.

Creación de la tabla optimizada

```
CREATE OR REPLACE TABLE `Proyecto2_G20.taxi_trips_2022_optimized`
```

Crea una nueva tabla llamada `taxi_trips_2022_optimized`.
Si ya existe, la reemplaza completamente.

Particionamiento de la tabla

```
PARTITION BY pickup_date
```

Divide la tabla en particiones según la columna `pickup_date`.

- Mejorar el rendimiento de consultas
- Reducir costos al escanear solo fechas necesarias

Clustering de la tabla

```
CLUSTER BY vendor_id, pickup_location_id, payment_type
```

Organiza físicamente los datos dentro de cada partición según estas columnas:

- `vendor_id`
- `pickup_location_id`
- `payment_type`

Optimizar consultas que filtren o agrupen por estos campos.

Uso de CTE (Common Table Expression)

```
WITH source_data AS (
```

Se define una tabla temporal llamada source_data para preparar los datos antes de insertarlos.

Selección de datos base

```
SELECT
  vendor_id,
  pickup_datetime,
  dropoff_datetime,
  DATE(pickup_datetime) AS pickup_date,
  ...
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
```

Descripción:
Se extraen columnas relevantes del dataset público.

Transformación clave:

- DATE(pickup_datetime) → crea pickup_date (clave para partición)

Filtro de fechas

```
WHERE DATE(pickup_datetime) BETWEEN '2022-01-01' AND '2022-12-31'
```

Descripción:
Limita los datos únicamente al año 2022.

Selección final y enriquecimiento de datos

```
SELECT
  vendor_id,
  pickup_datetime,
  ...
```

Se seleccionan todas las columnas necesarias y se agregan nuevas variables **derivadas**:

Duración del viaje

TIMESTAMP_DIFF(dropoff_datetime, pickup_datetime, MINUTE) AS trip_duration_minutes
Calcula la duración del viaje en minutos.
Hora de inicio
EXTRACT(HOUR FROM pickup_datetime) AS pickup_hour
Obtiene la hora del día (0–23).

Día de la semana
EXTRACT(DAYOFWEEK FROM pickup_datetime) AS pickup_day_of_week
Devuelve el día de la semana (1 = domingo, 7 = sábado).

Mes
EXTRACT(MONTH FROM pickup_datetime) AS pickup_month
Obtiene el mes (1–12).

Variable objetivo (propina alta)

IF(SAFE_DIVIDE(tip_amount, NULLIF(fare_amount, 0)) >= 0.20, 1, 0) AS is_high_tip

Descripción:

- Calcula el porcentaje de propina respecto a la tarifa
- Usa SAFE_DIVIDE para evitar errores de división por cero
- Usa NULLIF para evitar dividir entre 0

Resultado:

- 1 → propina ≥ 20%
- 0 → propina < 20%

Objetivo:
Crear una variable binaria para modelos de Machine Learning.

Filtros de limpieza de datos

```
WHERE pickup_datetime IS NOT NULL
  AND dropoff_datetime IS NOT NULL
  AND dropoff_datetime >= pickup_datetime
```

Asegura que:

- No haya valores nulos
- El viaje tenga lógica temporal correcta

AND passenger_count BETWEEN 1 AND 6
Elimina valores inválidos o atípicos en número de pasajeros.

AND trip_distance > 0 AND trip_distance <= 100

Filtra distancias:

- Evita viajes de 0
- Elimina outliers extremos (>100 millas)

AND fare_amount > 0 AND fare_amount <= 500
Mantiene tarifas realistas.

AND total_amount > 0;

Garantiza que el monto total sea válido.

Resumen de la creación de la tabla optimizada.

- Particionada por fecha
- Clusterizada por variables clave

Limpia datos

Genera nuevas variables (feature engineering)

Prepara los datos para análisis y Machine Learning

Comparación de Rendimiento.

SIN OPTIMIZACIÓN

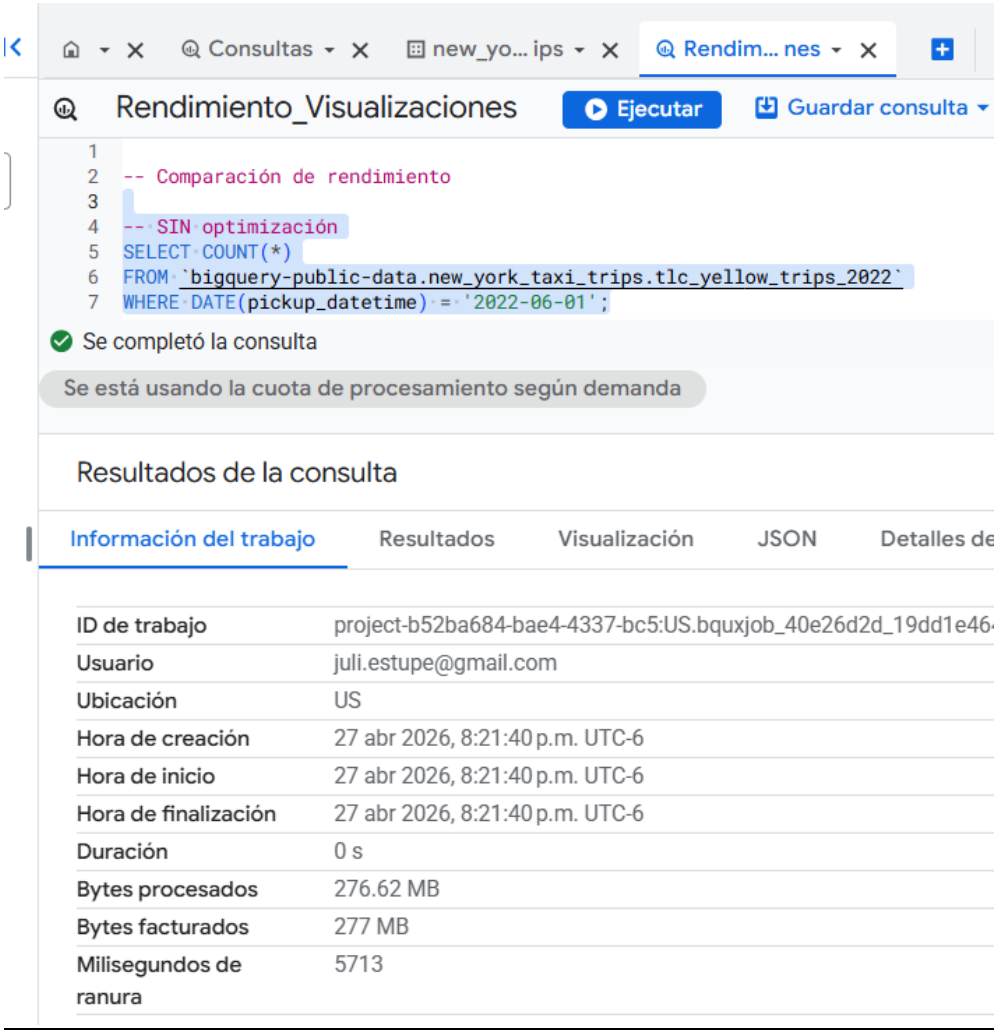

CON OPTIMIZACIÓN

Consultas | new_yo... ips | Rendim... nes

Rendimiento_Visualizaciones

Ejecutar | Guardar consulta | Descar

```
10
11  -- CON optimización
12  SELECT COUNT(*)
13  FROM `Proyecto2_G20.taxi_trips_2022_optimized`
14  WHERE pickup_date = '2022-06-01';
15
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo | Resultados | Visualización | JSON | Detalles de la ejecución

ID de trabajo	project-b52ba684-bae4-4337-bc5:US.bquxjob_4b6286_19dd1e02589 (Ver detalles d
Usuario	juli.estupe@gmail.com
Ubicación	US
Hora de creación	27 abr 2026, 8:17:01 p.m. UTC-6
Hora de inicio	27 abr 2026, 8:17:01 p.m. UTC-6
Hora de finalización	27 abr 2026, 8:17:02 p.m. UTC-6
Duración	0 s
Bytes procesados	886.46 KB
Bytes facturados	10 MB
Milisegundos de ranura	42

```sql
-- Consulta base sin optimización

-- Qué hace:

-- Convierte la fecha y hora en solo fecha (pickup_date)
-- Cuenta cuántos viajes hubo por día
-- Suma el dinero total generado por día

-- Para qué sirve:

-- Analizar la demanda diaria y los ingresos en un periodo específico (julio a
septiembre 2022)

SELECT
  DATE(pickup_datetime) AS pickup_date,
  COUNT(*) AS trips,
  ROUND(SUM(total_amount), 2) AS revenue
FROM `bigquery-public-data.new_york_taxi_trips.tlc_yellow_trips_2022`
WHERE DATE(pickup_datetime) BETWEEN '2022-07-01' AND '2022-09-30'
GROUP BY pickup_date
ORDER BY pickup_date;

-- Consulta sobre tabla optimizada

-- Qué hace:
-- Exactamente lo mismo que la anterior
-- Diferencia clave:
-- Usa una tabla particionada por fecha
-- Solo escanea los datos necesarios
--Para qué sirve:
-- Obtener el mismo análisis pero de forma más rápida y barata

SELECT
  pickup_date,
  COUNT(*) AS trips,
  ROUND(SUM(total_amount), 2) AS revenue
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
WHERE pickup_date BETWEEN '2022-07-01' AND '2022-09-30'
GROUP BY pickup_date
ORDER BY pickup_date;
```

VISUALIZACIONES.

VIAJES POR MES.

```
-- Descripción:
-- Cuenta la cantidad de viajes en cada mes del año.

-- ¿Para qué sirve?
-- Permite visualizar la demanda mensual y detectar patrones estacionales (meses
con más o menos actividad).
```

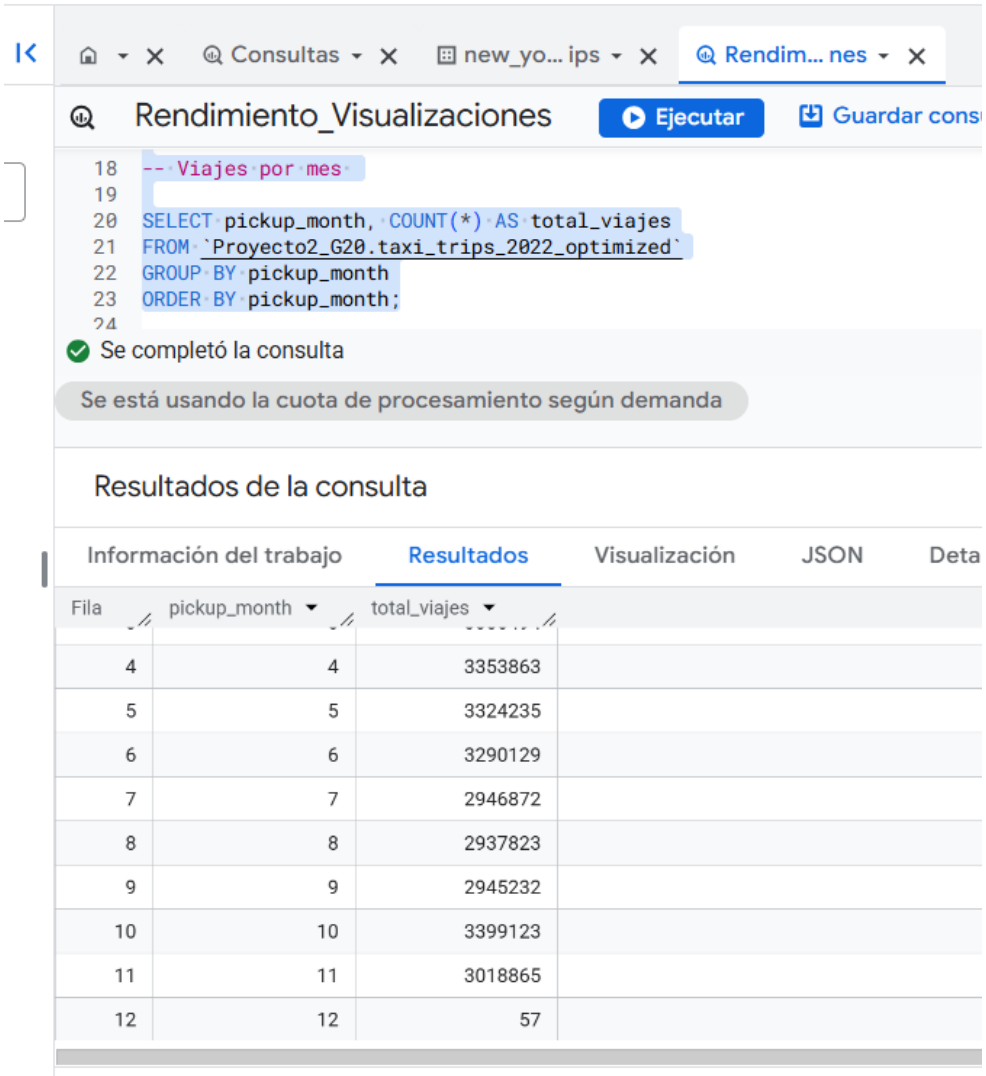

Fila	pickup_month	total_viajes
4	4	3353863
5	5	3324235
6	6	3290129
7	7	2946872
8	8	2937823
9	9	2945232
10	10	3399123
11	11	3018865
12	12	57

PROPINA PROMEDIO POR HORA

```
-- Descripción:
-- Calcula el promedio de propinas para cada hora del día (0–23).

-- ¿Para qué sirve?
-- Ayuda a identificar en qué horas los clientes dejan mejores propinas.
```

Consultas | new_yo... ips

Rendimiento_Visualizaciones | Ejecuta

```
-- Propina promedio por hora
SELECT pickup_hour, AVG(tip_amount) AS avg_tip
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
GROUP BY pickup_hour
ORDER BY pickup_hour;
```

Esta secuencia de comandos procesará 1.78 GB cuando se eje

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo | Resultados | Visualizació

Fila	pickup_hour	avg_tip
1	0	2.816471505
2	1	2.583944142
3	2	2.417347618
4	3	2.431729672
5	4	2.959567808
6	5	3.428584691
7	6	2.90583758
8	7	2.673931004
9	8	2.633504553

Información del trabajo | Resultados

Fila	pickup_hour	avg_tip
10	9	2.541603633
11	10	2.487614146
12	11	2.528800836
13	12	2.574508439
14	13	2.639050744
15	14	2.724850598
16	15	2.764574309
17	16	2.868616182
18	17	2.783545248
19	18	2.665467989
20	19	2.643326735
21	20	2.690579019
22	21	2.765101784
23	22	2.847611205
24	23	2.875569515

% DE PROPINAS ALTAS.

```
-- Descripción:
-- Calcula el porcentaje de viajes con propinas altas (≥20%) por día de la semana.

-- ¿Cómo funciona?

-- is_high_tip es 1 (sí) o 0 (no)
-- El promedio de esa columna equivale al porcentaje
-- Se multiplica por 100 para expresarlo en %

-- ¿Para qué sirve?
-- Permite ver qué días los clientes son más generosos con las propinas.
```

Consultas | new_yo... ips | *Ren

Rendimiento_Visualizaciones — Ejecutar

```
-- % de propinas altas

SELECT
  pickup_day_of_week,
  AVG(is_high_tip) * 100 AS porcentaje_propina_alta
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
GROUP BY pickup_day_of_week;
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo | Resultados | Visualización

Fila	pickup_day_of_w...	porcentaje_propina_alta
1	4	63.57805924951456
2	7	62.223793913382806
3	2	62.134282356725059
4	5	63.342318791113506
5	3	63.269599035332234
6	1	61.85157148146704
7	6	62.521256570794051

```sql
-- Top rutas por ingreso
-- Qué hace:
-- Analiza combinaciones origen → destino
-- Calcula:
-- Número de viajes
-- Ingreso total
-- Duración promedio
-- Para qué sirve:
-- Identificar las rutas más rentables
-- Ver cuáles trayectos generan más dinero

SELECT
  pickup_location_id,
  dropoff_location_id,
  COUNT(*) AS trips,
  ROUND(SUM(total_amount), 2) AS total_revenue,
  ROUND(AVG(trip_duration_minutes), 2) AS avg_trip_duration_minutes
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
GROUP BY pickup_location_id, dropoff_location_id
ORDER BY total_revenue DESC
LIMIT 25;

-- Comportamiento semanal
-- Qué hace:
-- Agrupa los viajes por día de la semana (1–7 o según tu definición)
-- Calcula:
-- Cantidad de viajes
-- Distancia promedio
-- Propina promedio
-- Para qué sirve:
-- Entender el patrón semanal
-- Detectar:
-- Días con más actividad
-- Días con viajes más largos o mejores propinas

SELECT
  pickup_day_of_week,
  COUNT(*) AS trips,
  ROUND(AVG(trip_distance), 2) AS avg_trip_distance,
  ROUND(AVG(tip_amount), 2) AS avg_tip_amount
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
GROUP BY pickup_day_of_week
ORDER BY pickup_day_of_week;
```

Creación de la tabla para ML

Conviene tener una tabla específica para ML, aunque técnicamente podrías entrenar directo desde tu tabla optimizada.

La razón por la que no se hace directamente es importante:

La tabla optimizada está pensada para análisis + consultas eficientes
Una tabla de ML está pensada para modelado (features limpias y controladas)

Si no se separa esto, puedes tener:

- data leakage
- variables mal definidas
- modelos poco claros.

```sql
-- Feature engineering

CREATE OR REPLACE TABLE `Proyecto2_G20.ml_features_taxi_2022`
PARTITION BY pickup_date
CLUSTER BY split_col, payment_type, pickup_location_id, dropoff_location_id
AS
SELECT
  -- Partición
  pickup_date,
  -- Features principales (INPUTS)
  passenger_count,  trip_distance,  fare_amount,  trip_duration_minutes,
  pickup_hour,  pickup_day_of_week,  pickup_month,  payment_type,
  pickup_location_id,  dropoff_location_id,
  -- Variables derivadas
  SAFE_DIVIDE(tip_amount, NULLIF(fare_amount, 0)) AS tip_pct,
  -- Targets
  is_high_tip,     -- clasificación
  tip_amount,      -- regresión
  -- Split temporal (evita data leakage)
  CASE
    WHEN pickup_date < '2022-10-01' THEN 'TRAIN'
    WHEN pickup_date < '2022-12-01' THEN 'EVAL'
    ELSE 'PREDICT'
  END AS split_col
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
WHERE
  pickup_date IS NOT NULL
  AND trip_duration_minutes BETWEEN 1 AND 180
  AND trip_distance BETWEEN 0.1 AND 100
  AND fare_amount BETWEEN 1 AND 300
  AND tip_amount BETWEEN 0 AND 200
  AND passenger_count BETWEEN 1 AND 6;
```

Descripcion de la tabla ml_features_taxi_2022

CREACIÓN DE LA TABLA

CREATE OR REPLACE TABLE `Proyecto2_G20.ml_features_taxi_2022`

Esto hace:

- Crea una nueva tabla para Machine Learning
- Si ya existe → la reemplaza

Es importante porque:

- separa la capa de ML de la tabla optimizada
- puedes controlar qué datos entran al modelo

PARTICIONAMIENTO

PARTITION BY pickup_date

Divide la tabla por fecha

¿Para qué sirve?

- consultas más rápidas
- menos costo (menos bytes)
- puedes filtrar por fechas fácilmente

Ejemplo: WHERE pickup_date = '2022-05-01' . solo lee esa partición.

CLUSTERING

CLUSTER BY split_col, payment_type, pickup_location_id, dropoff_location_id

Ordena los datos internamente por esas columnas

Beneficio:

mejora consultas como:

WHERE split_col = 'TRAIN'

Para fines del proyecto.

- split_col → clave para ML
- payment_type → comportamiento
- locations → análisis geográfico

SELECT (CONSTRUCCIÓN DEL DATASET)

Informacion del modelo.

Partición

pickup_date

Se usa para:

- particionar
- hacer el split temporal

Features (variables de entrada)

passenger_count,
trip_distance,
fare_amount,
trip_duration_minutes,
pickup_hour,
pickup_day_of_week,
pickup_month,
payment_type,
pickup_location_id,
dropoff_location_id

Estas son las variables que el modelo usará para aprender

Tipos de información:

- Geografía → locations
- Tiempo → hour, day, month
- Económico → fare_amount
- Viaje → distancia, duración
- Usuario → passenger_count

Variable derivada

```
SAFE_DIVIDE(tip_amount, NULLIF(fare_amount, 0)) AS tip_pct,
```

Calcula el porcentaje de propina

¿Qué hace exactamente?

- NULLIF(fare_amount, 0)
  → evita dividir entre 0
- SAFE_DIVIDE
  → evita errores (si algo falla → devuelve NULL)

Resultado:

tip_pct = tip_amount / fare_amount

Esto captura comportamiento del cliente

Variables objetivo (targets)

```
is_high_tip,
tip_amount
```

Definen qué quieres predecir

Clasificación:

- is_high_tip → 1 o 0

Regresión:

- tip_amount → valor continuo

Split temporal (LO MÁS IMPORTANTE)

```
CASE
  WHEN pickup_date < '2022-10-01' THEN 'TRAIN'
  WHEN pickup_date < '2022-12-01' THEN 'EVAL'
  ELSE 'PREDICT'
END AS split_col
```

Divide los datos en 3 grupos:

Tipo	Uso
TRAIN	Entrenar modelo
EVAL	Evaluar modelo
PREDICT	Simular futuro

¿Por qué esto es tan importante?

Porque evita **data leakage**

El modelo:

- aprende del pasado
- se evalúa en datos nuevos
- predice en datos futuros

Esto simula el mundo real.

FROM (ORIGEN DE DATOS)

```
FROM `Proyecto2_G20.taxi_trips_2022_optimized`
```

Usas tu tabla optimizada

Ventajas:

- datos limpios
- ya filtrados
- más rápido

FILTROS (LIMPIEZA FINAL)

```
WHERE
 pickup_date IS NOT NULL
```

Evita datos incompletos

```
trip_duration_minutes BETWEEN 1 AND 180
```

elimina:

- viajes de 0 min
- viajes absurdamente largos

```
----

  trip_distance BETWEEN 0.1 AND 100

elimina:

   ●  viajes irreales

----

  fare_amount BETWEEN 1 AND 300
       evita outliers de precio
----

  tip_amount BETWEEN 0 AND 200
       evita propinas absurdas
----

  passenger_count BETWEEN 1 AND 6;
       elimina errores de captura
```

Consulta de la distribución de dataset para ML.

```sql
SELECT
  split_col,
  COUNT(*) AS rows_in_split
FROM `Proyecto2_G20.ml_features_taxi_2022`
GROUP BY split_col
ORDER BY split_col;
```

¿QUÉ HACE EN GENERAL?

Cuenta cuántos registros hay en cada grupo de datos:

- TRAIN
- EVAL
- PREDICT

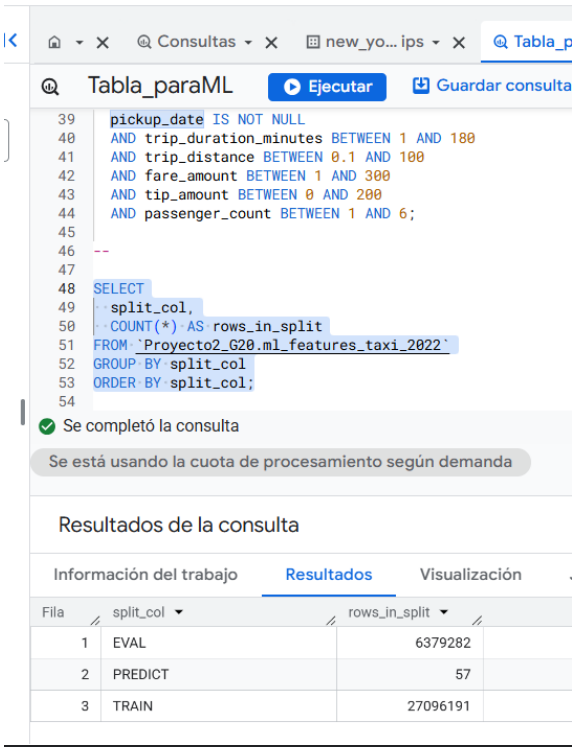

BLOQUE DE MACHINE LEARNING COMPLETO.

```
-- MODELO 1: CLASIFICACIÓN (PROPINA ALTA)
-- Objetivo: predecir si un viaje tendrá propina alta (is_high_tip)
-- Esta consulta crea un modelo de regresión logística que aprende a predecir si un
viaje tendrá una propina alta (is_high_tip).
-- Se entrena únicamente con los datos del conjunto TRAIN, utilizando variables
como distancia, monto, tiempo y ubicación del viaje.
CREATE OR REPLACE MODEL `Proyecto2_G20.modelo_clasificacion`
OPTIONS(
  model_type = 'logistic_reg',
  input_label_cols = ['is_high_tip']
) AS
SELECT
  passenger_count,  trip_distance,  fare_amount,  trip_duration_minutes,
  pickup_hour,  pickup_day_of_week,  pickup_month,
  payment_type,  pickup_location_id,  dropoff_location_id,  is_high_tip
FROM `Proyecto2_G20.ml_features_taxi_2022`
WHERE split_col = 'TRAIN';
```

```sql
-- EVALUACIÓN (USANDO EVAL)

-- Esta consulta evalúa el modelo usando los datos de EVAL, es decir, datos que el modelo no vio durante el entrenamiento.

-- Permite medir su desempeño mediante métricas como accuracy, precision, recall y ROC AUC, indicando qué tan bien predice las propinas altas.

SELECT *
FROM ML.EVALUATE(
  MODEL `Proyecto2_G20.modelo_clasificacion`,
  (
    SELECT
      passenger_count,
      trip_distance,
      fare_amount,
      trip_duration_minutes,
      pickup_hour,
      pickup_day_of_week,
      pickup_month,
      payment_type,
      pickup_location_id,
      dropoff_location_id,
      is_high_tip
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'EVAL'
  )
);
```

Consultas | new_yo... ips | *ML_MO...LOS

ML_MODELOS

Ejecutar | Guardar consulta | Descargar | Compartir | Progr

```
FROM ML.EVALUATE(
  MODEL `Proyecto2_G20.modelo_clasificacion`,
  (
    SELECT
      passenger_count,
      trip_distance,
      fare_amount,
      trip_duration_minutes,
      pickup_hour,
      pickup_day_of_week,
      pickup_month,
      payment_type,
      pickup_location_id,
      dropoff_location_id,
      is_high_tip
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'EVAL'
  )
);

-- PREDICCIONES.
```

Se completó la consulta

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo | Resultados | Visualización | JSON | Detalles de la ejecución | Gráfico de ejec

Fila	precision	recall	accuracy	f1_score	log_loss	roc_auc
1	0.796214413278...	0.996476824712...	0.835303408753...	0.885159913229...	0.410726789458...	0.819836163836...

```sql
-- PREDICCIONES.

-- Esta consulta aplica el modelo sobre datos nuevos (PREDICT) para estimar si un viaje tendrá propina alta.

-- Devuelve:
-- la predicción (0 o 1)
-- la probabilidad asociada

SELECT
  *,
  predicted_is_high_tip,
  predicted_is_high_tip_probs
FROM ML.PREDICT(
  MODEL `Proyecto2_G20.modelo_clasificacion`,
  (
    SELECT
      passenger_count,
      trip_distance,
      fare_amount,
      trip_duration_minutes,
      pickup_hour,
      pickup_day_of_week,
      pickup_month,
      payment_type,
      pickup_location_id,
      dropoff_location_id
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'PREDICT'
  )
);
```

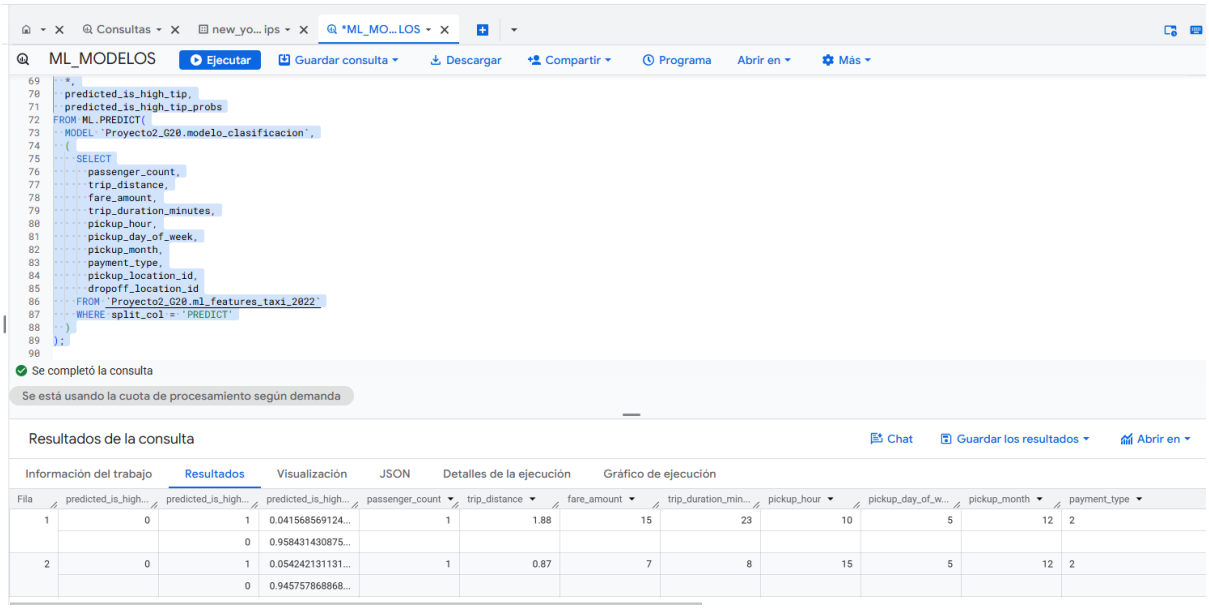


```
--  GUARDAR PREDICCIONES

-- Esta consulta guarda los resultados de las predicciones en una nueva tabla
(predicciones_clasificacion).
-- Esto permite usar los resultados posteriormente en visualizaciones o análisis.
CREATE OR REPLACE TABLE `Proyecto2_G20.predicciones_clasificacion` AS
SELECT
  *
FROM ML.PREDICT(
  MODEL `Proyecto2_G20.modelo_clasificacion`,
  (
    SELECT
      passenger_count,      trip_distance,      fare_amount,
      trip_duration_minutes,      pickup_hour,      pickup_day_of_week,
      pickup_month,      payment_type,      pickup_location_id,
      dropoff_location_id
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'PREDICT'
  )
);
```

```sql
-- MODELO 2: REGRESIÓN (MONTO DE PROPINA)

-- Objetivo: predecir cuánto será la propina (tip_amount)

-- Esta consulta crea un modelo de regresión lineal que predice el monto exacto de
la propina (tip_amount).

-- Se entrena con datos del conjunto TRAIN, utilizando variables del viaje como
distancia, tarifa, tiempo y ubicación.

CREATE OR REPLACE MODEL `Proyecto2_G20.modelo_regresion`
OPTIONS(
  model_type = 'linear_reg',
  input_label_cols = ['tip_amount']
) AS
SELECT
  passenger_count,
  trip_distance,
  fare_amount,
  trip_duration_minutes,
  pickup_hour,
  pickup_day_of_week,
  pickup_month,
  payment_type,
  pickup_location_id,
  dropoff_location_id,
  tip_amount
FROM `Proyecto2_G20.ml_features_taxi_2022`
WHERE split_col = 'TRAIN';
```

```sql
-- EVALUACIÓN REGRESIÓN

-- Esta consulta evalúa el modelo con datos de EVAL, midiendo su precisión mediante métricas como el RMSE (error cuadrático medio).

-- Permite determinar qué tan cerca están las predicciones de los valores reales.

SELECT *
FROM ML.EVALUATE(
  MODEL `Proyecto2_G20.modelo_regresion`,
  (
    SELECT
      passenger_count,
      trip_distance,
      fare_amount,
      trip_duration_minutes,
      pickup_hour,
      pickup_day_of_week,
      pickup_month,
      payment_type,
      pickup_location_id,
      dropoff_location_id,
      tip_amount
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'EVAL'
  )
);
```

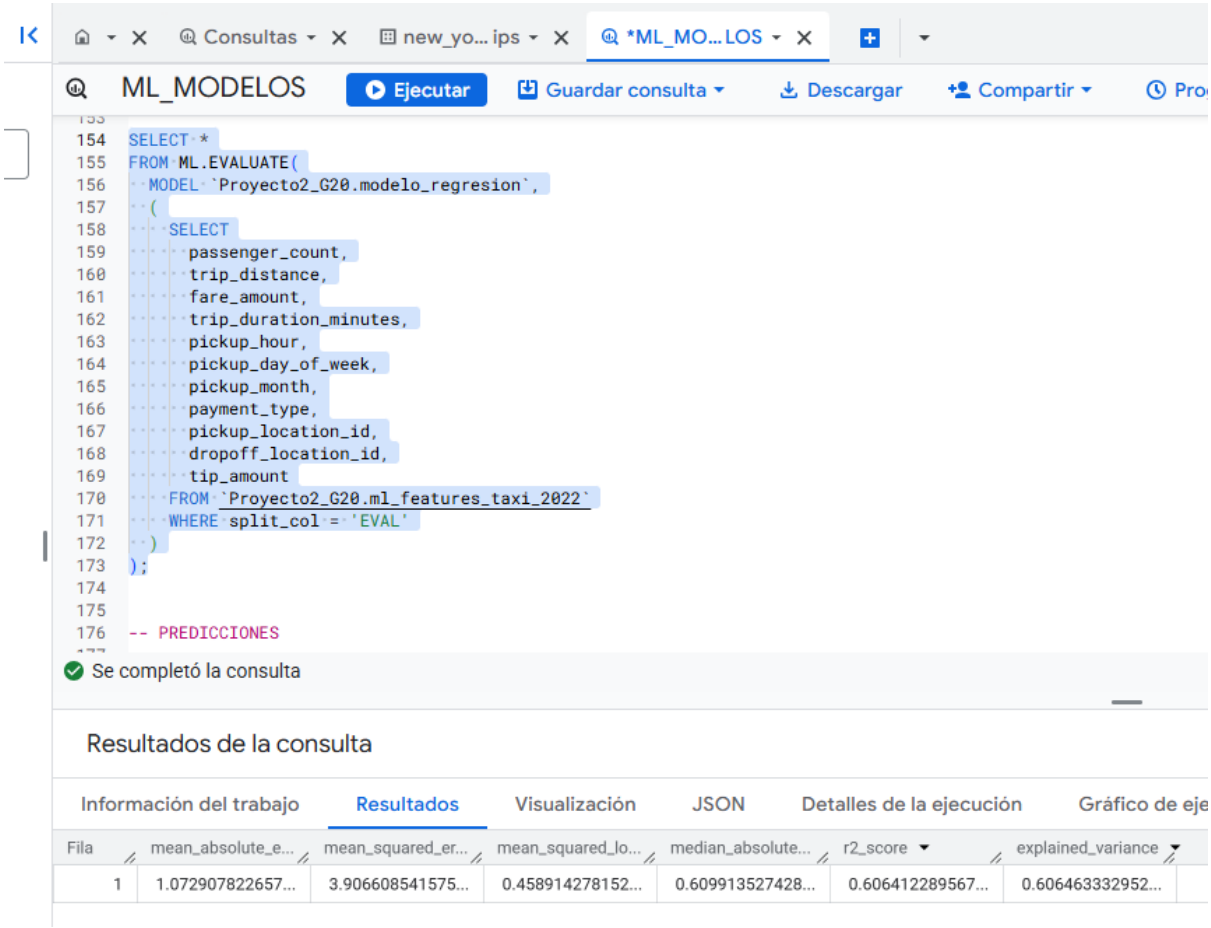


```
-- PREDICCIONES

-- Esta consulta usa el modelo para estimar el monto de la propina en datos nuevos
(PREDICT).
-- Devuelve el valor estimado (predicted_tip_amount) para cada viaje.
SELECT  *,  predicted_tip_amount
FROM ML.PREDICT(
  MODEL `Proyecto2_G20.modelo_regresion`,
  (
    SELECT
      passenger_count,      trip_distance,      fare_amount,
      trip_duration_minutes,      pickup_hour,      pickup_day_of_week,
      pickup_month,      payment_type,      pickup_location_id,
      dropoff_location_id
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'PREDICT'
  )
);
```

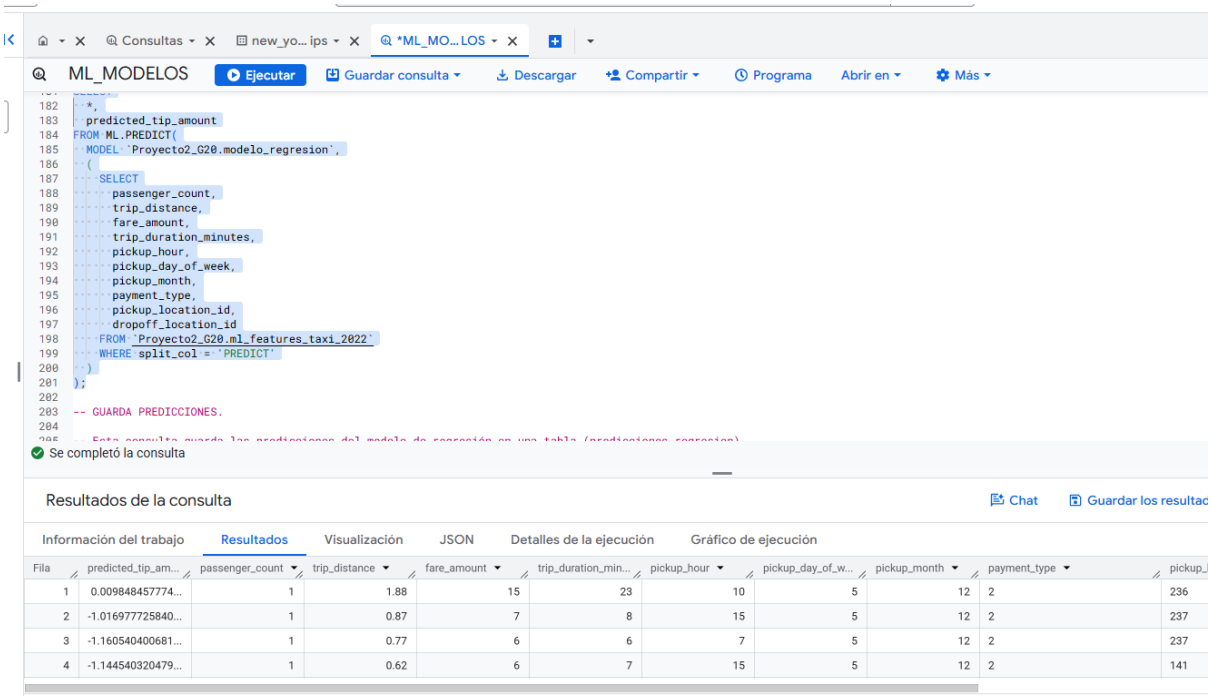


```
-- GUARDA PREDICCIONES.

-- Esta consulta guarda las predicciones del modelo de regresión en una tabla
(predicciones_regresion).
-- Esto facilita su uso en dashboards o comparaciones posteriores.
CREATE OR REPLACE TABLE `Proyecto2_G20.predicciones_regresion` AS
SELECT
  *
FROM ML.PREDICT(
  MODEL `Proyecto2_G20.modelo_regresion`,
  (
    SELECT
      passenger_count,      trip_distance,
      fare_amount,      trip_duration_minutes,
      pickup_hour,      pickup_day_of_week,
      pickup_month,      payment_type,
      pickup_location_id,      dropoff_location_id
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'PREDICT'
  )
);
```

```sql
-- ¿PARA QUÉ SIRVE ML.CONFUSION_MATRIX?

-- La matriz de confusión sirve para ver qué tan bien está clasificando el modelo,
no solo en general, sino exactamente en qué acierta y en qué se equivoca.

-- Modelo de clasificación → is_high_tip (0 o 1)
-- ¿QUÉ ANALIZA?
-- Compara:
-- VALOR REAL  vs  VALOR PREDICHO

SELECT *
FROM ML.CONFUSION_MATRIX(
  MODEL `Proyecto2_G20.modelo_clasificacion`,
  (
    SELECT
      passenger_count,
      trip_distance,
      fare_amount,
      trip_duration_minutes,
      pickup_hour,
      pickup_day_of_week,
      pickup_month,
      payment_type,
      pickup_location_id,
      dropoff_location_id,
      is_high_tip
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'EVAL'
  )
);
```

Consultas | new_yo... ips | *ML_MO... LOS

ML_MODELOS

Ejecutar | Guardar consulta | Descarga

```
FROM ML.CONFUSION_MATRIX(
  MODEL `Proyecto2_G20.modelo_clasificacion`,
  (
    SELECT
      passenger_count,
      trip_distance,
      fare_amount,
      trip_duration_minutes,
      pickup_hour,
      pickup_day_of_week,
      pickup_month,
      payment_type,
      pickup_location_id,
      dropoff_location_id,
      is_high_tip
    FROM `Proyecto2_G20.ml_features_taxi_2022`
    WHERE split_col = 'EVAL'
```

Esta secuencia de comandos procesará 3.1 GB cuando se ejecute.

Se está usando la cuota de procesamiento según demanda

Resultados de la consulta

Información del trabajo | Resultados | Visualización | JSON | Detalles

Fila	expected_label	_0	_1
1	0	1279572	1036330
2	1	14316	4049064

MATRIZ DE CONFUSIÓN, ESTUDIANDO RESULTADO PARA EL MODELO DE CLASIFICACIÓN.

expected_label	pred 0	pred 1
0	1,279,572	1,036,330
1	14,316	4,049,064

¿QUÉ SIGNIFICA?

- expected_label = valor real
- Columnas (_0, _1) = predicción del modelo

INTERPRETACIÓN FILA POR FILA

1. Casos donde NO hay propina alta (0)

Real = 0

- 1,279,572 → el modelo predijo bien (TN)
- 1,036,330 → el modelo se equivocó (FP)

Problema:
El modelo predice demasiadas propinas altas cuando no lo son.

2. Casos donde SÍ hay propina alta (1)

Real = 1

- 4,049,064 → aciertos (TP)
- 14,316 → errores (FN)

Muy buen resultado aquí:
El modelo detecta casi todas las propinas altas.

RESUMEN CLAVE

Tipo	Valor	Interpretación
TP (Verdadero positivo)	4,049,064	Excelente (detecta bien propinas altas)
TN (Verdadero negativo)	1,279,572	Aceptable
FP (Falsos positivos)	1,036,330	Alto (muchos falsos positivos)
FN (Falsos negativos)	14,316	Muy bajo (casi no falla aquí)

El modelo presenta un alto desempeño en la detección de propinas altas, con un número muy bajo de falsos negativos, lo que indica que rara vez deja de identificar estos casos. Sin embargo, presenta una cantidad considerable de falsos positivos, lo que implica que tiende a sobreestimar la probabilidad de propinas altas.

CÁLCULO DEL RMSE (ROOT MEAN SQUARED ERROR),PARA EL MODELO DE REGRESION.

Definición

El **RMSE (Root Mean Squared Error)** es una métrica utilizada para evaluar modelos de regresión. Mide la diferencia promedio entre los valores reales y los valores predichos por el modelo.

Fórmula

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

Donde:

- y_i = valor real
- $\hat{y}_i$ = valor predicho
- n = número de observaciones

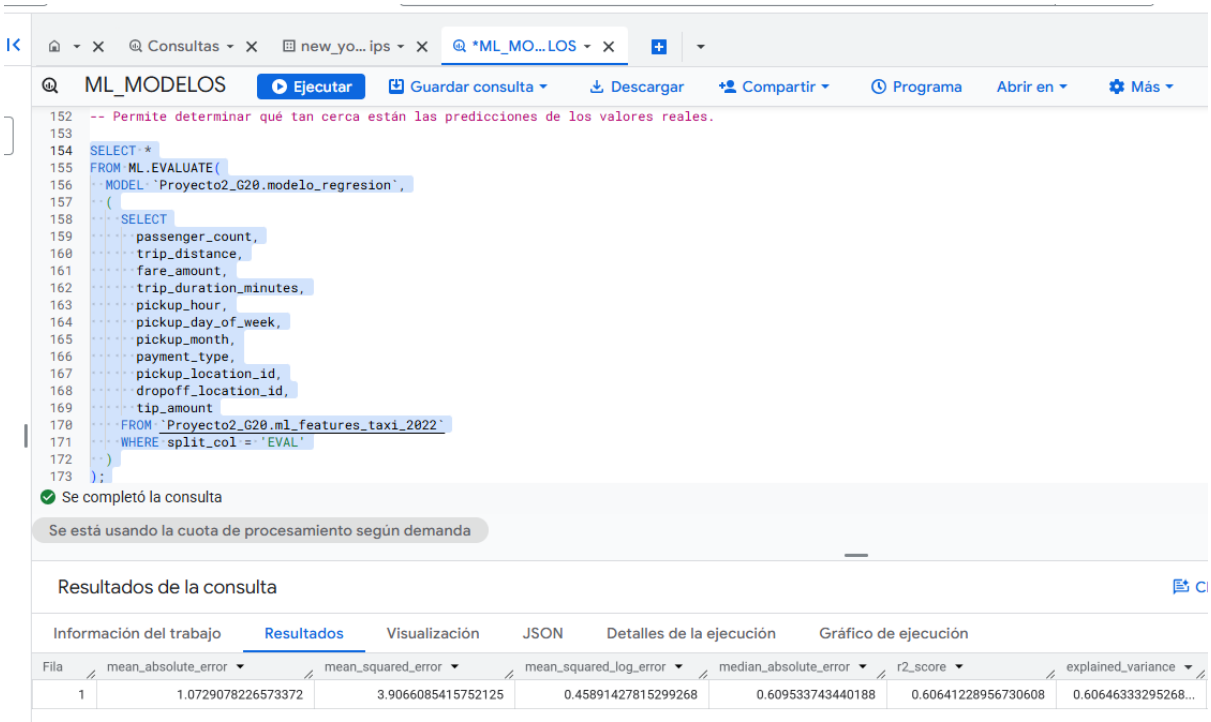

mean_squared_error = 3.9066085

EL RMSE se obtiene así: RMSE = √(mean_squared_error)

CÁLCULO : RMSE = √3.9066 ≈ 1.98

INTERPRETACIÓN : En promedio, EL modelo se equivoca aproximadamente en $1.98 al predecir la propina.

Informacion adicional:

mean_absolute_error ≈ 1.07 → error promedio sin cuadrado
r2_score ≈ 0.60 → el modelo explica ~60% de la variabilidad
explained_variance ≈ 0.60 → consistente con R^2

Resumen.

El modelo de regresión obtuvo un RMSE aproximado de 1.98, lo que indica que, en promedio, las predicciones de propina difieren en alrededor de $2 respecto al valor real. Este resultado se considera adecuado dentro del contexto del dataset, donde las propinas presentan valores relativamente bajos.

COMPARACIÓN ENTRE MODELOS

En el proyecto se implementaron dos modelos predictivos utilizando BigQuery ML: un modelo de clasificación (Logistic Regression) y un modelo de regresión (Linear Regression), cada uno con objetivos y métricas distintas.

DIFERENCIA DE OBJETIVO

Modelo de clasificación: Predice si un viaje tendrá una propina alta (is_high_tip), es decir, una variable categórica (0 o 1).

Modelo de regresión: Predice el valor exacto de la propina (tip_amount), una variable numérica continua.

COMPARACIÓN DE MÉTRICAS

Clasificación

Se evaluó mediante:

- Accuracy: porcentaje de predicciones correctas
- Precision: proporción de predicciones positivas correctas
- Recall: capacidad de detectar casos positivos
- Matriz de confusión: análisis detallado de aciertos y errores

Interpretación:
El modelo mostró un alto recall, lo que indica una buena capacidad para detectar propinas altas, aunque con una cantidad considerable de falsos positivos, afectando la precisión.

Regresión

Se evaluó mediante:

- RMSE: error promedio de predicción
- MAE: error absoluto promedio
- R^2: proporción de variabilidad explicada

Interpretación:
El modelo presentó un RMSE bajo, indicando buena precisión en la estimación de la propina. El valor de R^2 sugiere que el modelo explica una parte significativa de la variabilidad de los datos.

COMPARACIÓN DE HIPERPARÁMETROS

Ambos modelos utilizaron configuraciones estándar de BigQuery ML:

- Clasificación: logistic_reg
- Regresión: linear_reg

No se realizó ajuste avanzado de hiperparámetros, sin embargo:

- El modelo de clasificación se vio influenciado por la distribución de clases (propinas altas vs bajas)
- El modelo de regresión depende de la relación lineal entre variables

Esto indica que existe potencial de mejora mediante tuning de hiperparámetros.

CONCLUSIÓN COMPARATIVA

- El modelo de **clasificación** es útil para identificar patrones de comportamiento (si habrá propina alta), destacando por su alta capacidad de detección (recall), aunque con menor precisión.
- El modelo de **regresión** permite estimar el valor exacto de la propina, mostrando un error relativamente bajo y una buena capacidad explicativa.

Ambos modelos son complementarios:

- **uno clasifica comportamiento**
- **el otro cuantifica el resultado**

El modelo de clasificación presentó un alto recall, siendo efectivo en la detección de propinas altas, aunque con tendencia a generar falsos positivos. Por otro lado, el modelo de regresión mostró un RMSE bajo y un R^2 aceptable, indicando una buena capacidad para estimar el monto de la propina. Ambos modelos cumplen funciones complementarias dentro del análisis predictivo.

LOOKER STUDIO

Click en **"Crear"** → **"Informe"**

Conectar BigQuery

PASO 2: Conectar BigQuery

1. Selecciona:
   BigQuery
2. Busca tu proyecto:
   Proyecto2_G20
3. Selecciona tabla:
   taxi_trips_2022_optimized
   Click en **"Agregar"**

VIAJES POR MES

Paso 1: Insertar gráfico

Arriba en el menú:
Click en:
Añadir un gráfico
Selecciona:
Gráfico de barras
Luego haz clic en el lienzo (pantalla blanca)

Paso 2: Configurar datos (lado derecho)

En el panel derecho:

Dimensión:
Cambia a:
pickup_month
Métrica:
Cambia a:
Conteo de registros
(Si no aparece, usa COUNT(*))

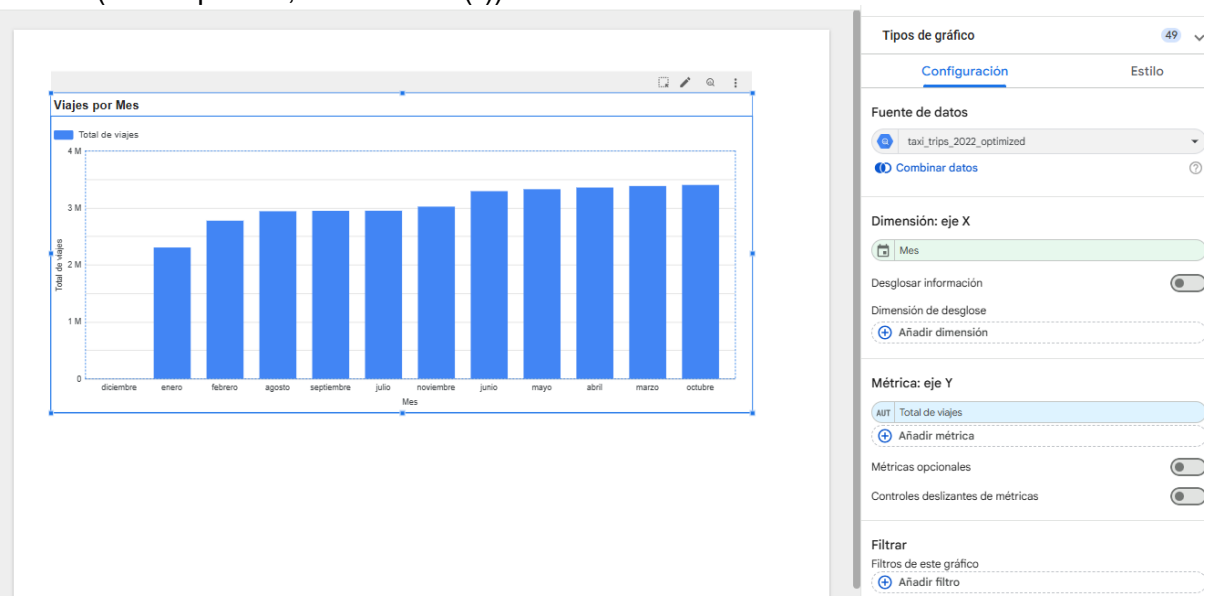

PROPINA POR HORA

Paso 1: Insertar gráfico

Añadir un gráfico →
Selecciona:
Gráfico de líneas

Clic en el lienzo

Paso 2: Configurar

Dimensión:

pickup_hour

Métrica:

tip_amount
Y asegúrate que diga:
Promedio (AVG)
(si no → cambia agregación a PROMEDIO)

Resultado esperado

Línea mostrando cómo cambian las propinas durante el día

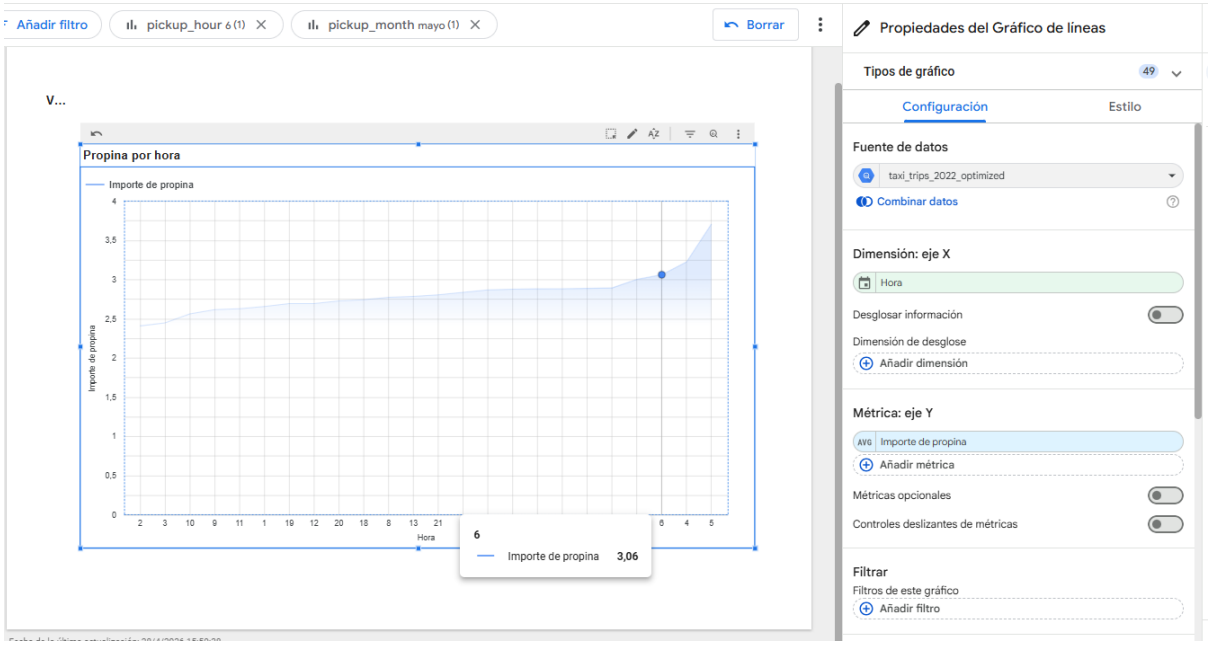

<u>% PROPINAS ALTAS</u>

Paso 1: Insertar gráfico

Añadir un gráfico →
Selecciona:

Gráfico de barras

Clic en el lienzo

Paso 2: Configurar

Dimensión:

pickup_day_of_week

Métrica:

is_high_tip

Cambia agregación a:

Promedio (AVG)

Paso 3: (IMPORTANTE) convertir a %

Crear campo:

Click en:

Añadir un campo

Nombre:

porcentaje_propina_alta

Fórmula:

is_high_tip * 100

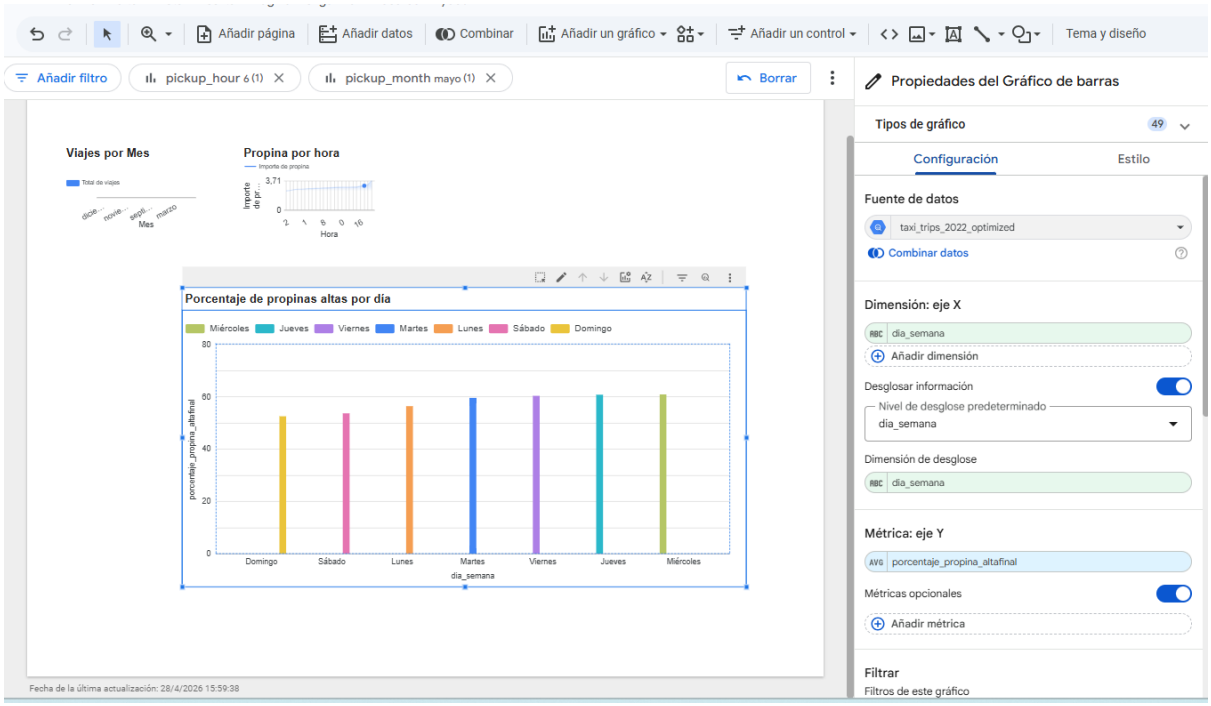
Añadir página
Añadir datos
Combinar
Añadir un gráfico
Añadir un control
Tema y diseño
Añadir filtro
pickup_hour 6 (1)
pickup_month mayo (1)
Borrar
Viajes por Mes
Total de viajes
Mes
Propina por hora
Importe de propina
Hora
Porcentaje de propinas altas por día
Miércoles
Jueves
Viernes
Martes
Lunes
Sábado
Domingo
porcentaje_propina_altafinal
dia_semana
Fecha de la última actualización: 28/4/2026 15:59:38
Propiedades del Gráfico de barras
Tipos de gráfico
Configuración
Estilo
Fuente de datos
taxi_trips_2022_optimized
Combinar datos
Dimensión: eje X
dia_semana
Añadir dimensión
Desglosar información
Nivel de desglose predeterminado
dia_semana
Dimensión de desglose
dia_semana
Métrica: eje Y
porcentaje_propina_altafinal
Métricas opcionales
Añadir métrica
Filtrar
Filtros de este gráfico

Analisis Exploratorio NYC Taxi Trips 2022

Viajes por Mes

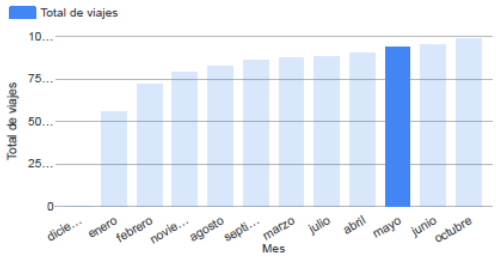

Propina por hora

Porcentaje de propinas altas por día

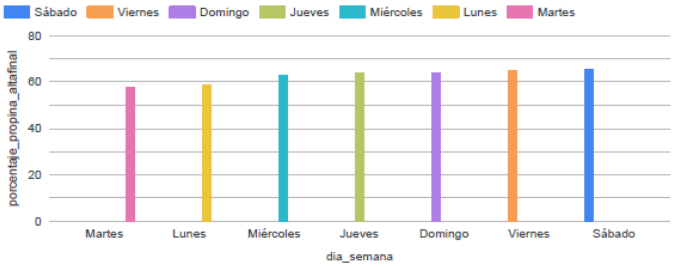

---

link:
https://datastudio.google.com/s/rARe94DwxIg

Tabla predicciones_clasificacion_clean

CREATE OR REPLACE TABLE `Proyecto2_G20.predicciones_clasificacion_clean` AS

```
CREATE OR REPLACE TABLE `Proyecto2_G20.predicciones_clasificacion_clean` AS
SELECT
  CAST(pickup_hour AS INT64) AS pickup_hour,
  CAST(pickup_day_of_week AS INT64) AS pickup_day_of_week,

  -- Probabilidad promedio de propina alta
  AVG(
    CASE
      WHEN prob.label = 1 THEN prob.prob
    END
  ) AS prob_propina_alta,

  -- Porcentaje de predicciones de propina alta
  AVG(CAST(predicted_is_high_tip AS FLOAT64)) AS tasa_prediccion_alta

FROM `Proyecto2_G20.predicciones_clasificacion`,
UNNEST(predicted_is_high_tip_probs) AS prob

GROUP BY pickup_hour, pickup_day_of_week;
```

¿Qué hace esta consulta?

1. Toma las predicciones generadas por el modelo de clasificación (modelo_clasificacion).
2. Desanida (UNNEST) las probabilidades del modelo.
3. Calcula métricas agregadas por:
    - Hora del día (pickup_hour)
    - Día de la semana (pickup_day_of_week)

¿Qué calcula exactamente?

- prob_propina_alta
  Promedio de la probabilidad de que el viaje tenga propina alta (clase 1).
- tasa_prediccion_alta
  Porcentaje de viajes que el modelo clasificó como propina alta.

¿Para qué sirve?

Permite analizar el comportamiento predictivo del modelo por hora y por día, facilitando la visualización en el dashboard.

Grafica "Probabilidad de Propina Alta por Hora"

Paso a paso en Looker Studio

Paso 1 — Conectar BigQuery

1. Ir a Looker Studio
2. `Crear → Informe`
3. Añadir fuente de datos
4. Seleccionar:
    - Proyecto: Proyecto2_G20
    - Dataset: Proyecto2_G20
    - Tabla: predicciones_clasificacion_clean
5. Conectar

Paso 2 — Insertar gráfico

1. Clic en "Agregar gráfico"
2. `Seleccionar → Gráfico de barras`

Paso 3 — Configuración del gráfico

En el panel derecho:

Dimensión (Eje X):

pickup_hour

Tipo: Número (entero)

Métrica (Eje Y):

prob_propina_alta

Agregación:

Promedio (AVG)

Paso 4 — Ordenar correctamente

En configuración:

Ordenar por:

pickup_hour ASC

Para que vaya de 0 a 23.

Resultado esperado

Gráfico de barras donde:

- Eje X → Hora del día
- Eje Y → Probabilidad promedio de propina alta
- Se observa mayor probabilidad en horas nocturnas

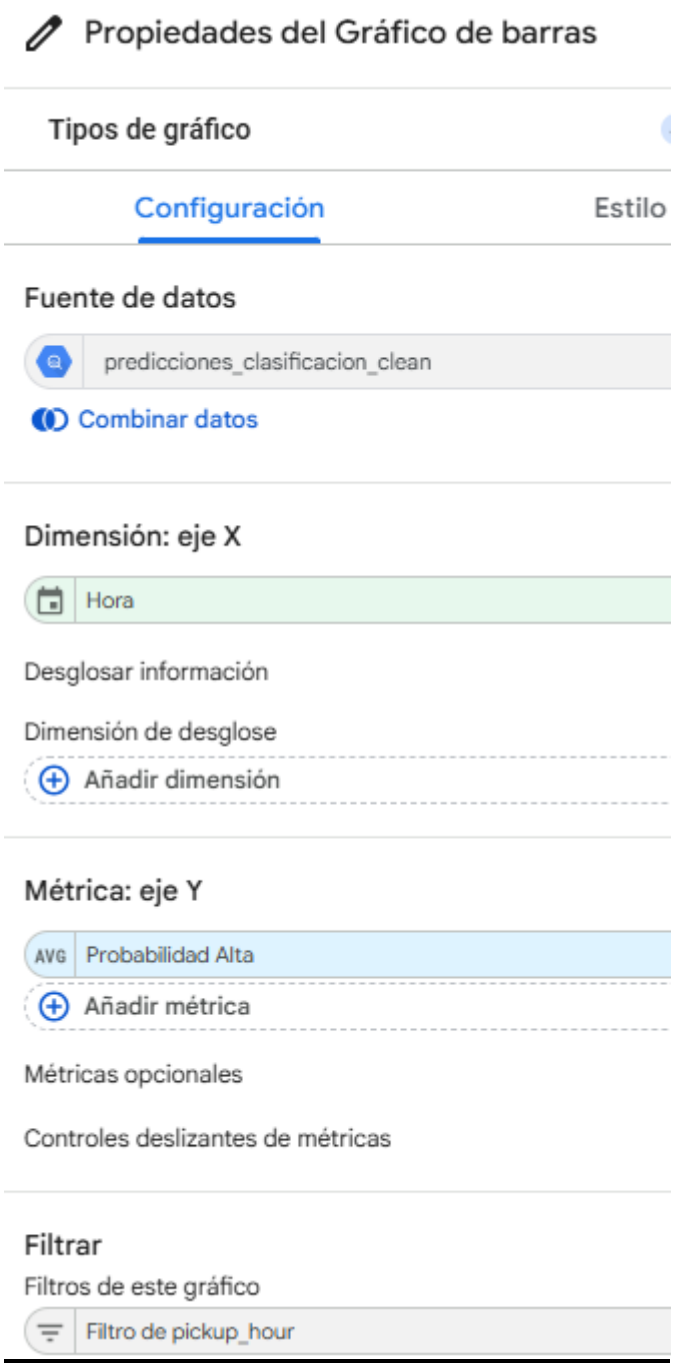

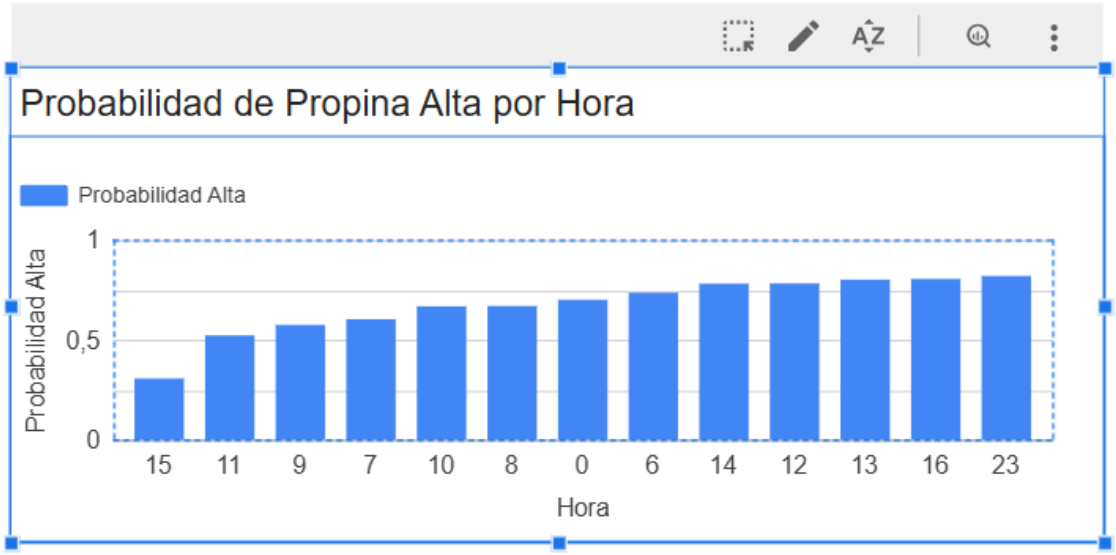

Gráfica "Propina Alta por Día de la Semana"

Paso 1 — Insertar gráfico

```
Agregar gráfico → Gráfico de barras horizontal
```

Paso 2 — Configuración

Dimensión:
pickup_day_of_week

Métrica:
prob_propina_alta

Agregación:
Promedio

Looker Studio, Se crea un campo calculado:

```
CASE
 WHEN pickup_day_of_week = 1 THEN "Domingo"
 WHEN pickup_day_of_week = 2 THEN "Lunes"
 WHEN pickup_day_of_week = 3 THEN "Martes"
 WHEN pickup_day_of_week = 4 THEN "Miércoles"
 WHEN pickup_day_of_week = 5 THEN "Jueves"
 WHEN pickup_day_of_week = 6 THEN "Viernes"
 WHEN pickup_day_of_week = 7 THEN "Sábado"
END
```

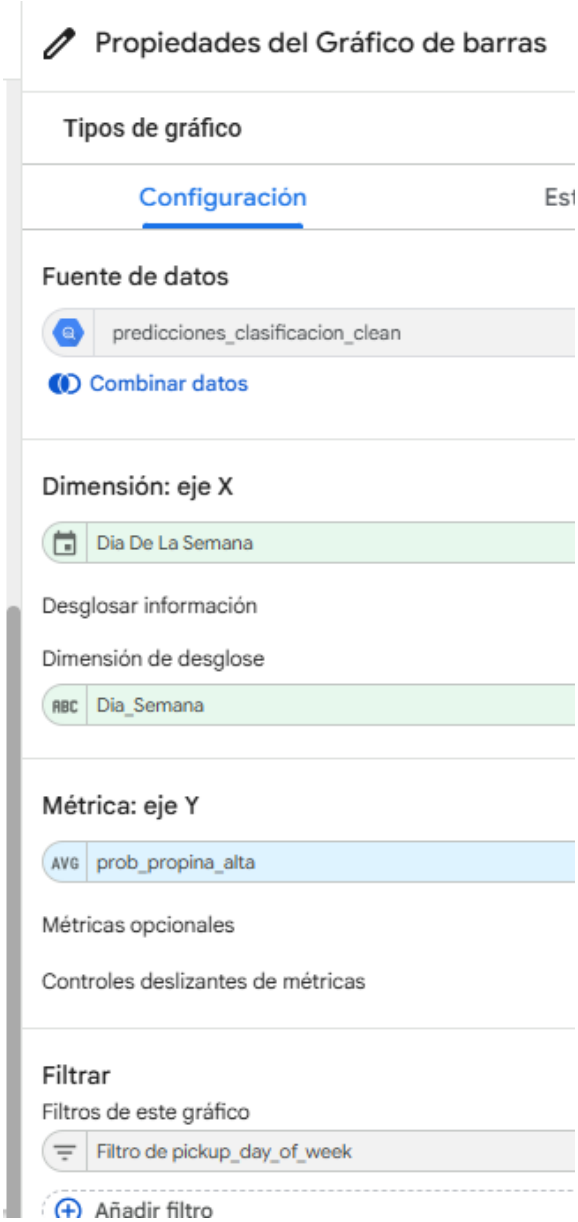
Propiedades del Gráfico de barras
Tipos de gráfico
Configuración
Est
Fuente de datos
predicciones_clasificacion_clean
Combinar datos
Dimensión: eje X
Dia De La Semana
Desglosar información
Dimensión de desglose
Dia_Semana
Métrica: eje Y
AVG
prob_propina_alta
Métricas opcionales
Controles deslizantes de métricas
Filtrar
Filtros de este gráfico
Filtro de pickup_day_of_week
Añadir filtro

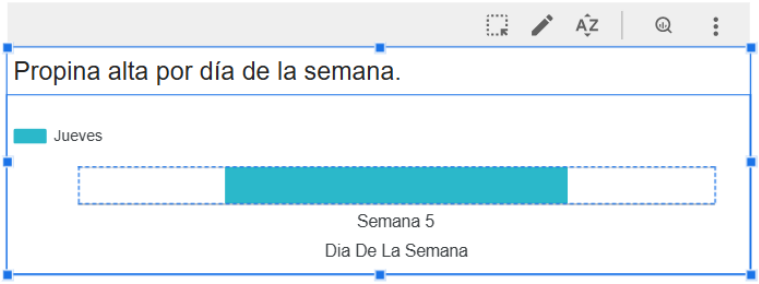
Propina alta por día de la semana.
Jueves
Semana 5
Dia De La Semana

Resumen:

El análisis muestra que la probabilidad de propinas altas aumenta durante las horas nocturnas, especialmente entre las 18:00 y 23:00. Además, los fines de semana presentan una mayor probabilidad promedio de propina alta, lo cual sugiere un comportamiento más generoso en periodos de ocio.

Generación de Gráficas a partir de predicciones_regresion

Generación de la tabla de predicciones en BigQuery

Objetivo

Guardar las predicciones del modelo de regresión en una tabla física para poder utilizarlas en dashboards.

Conectar Looker Studio a BigQuery

Agregar fuente de datos

- Seleccionar **BigQuery**
- Proyecto: `Proyecto2_G20`
- Dataset correspondiente
- Tabla: `predicciones_regresion`
- Clic en "Añadir"

GRÁFICA 1

Relación entre Distancia del Viaje y Propina Estimada

Objetivo

Analizar si existe relación entre la distancia del viaje y la propina estimada por el modelo.

PASOS PARA CREARLA

Insertar gráfico

Insertar → Gráfico → Dispersión

Configuración

En el panel derecho:

Fuente de datos: `predicciones_regresion`

Dimensión:
trip_distance
Métrica eje X:
AVG(trip_distance)
Métrica eje Y:
AVG(predicted_tip_amount)
⚠ Importante: usar AVG y no SUM.

Interpretación de la Gráfica 1

- Se observa relación positiva.
- A mayor distancia → mayor propina estimada.
- La mayoría de viajes están entre 0 y 5 millas.
- Existe un valor atípico cercano a 25 millas con propina alta.
- Algunos valores negativos aparecen debido a la naturaleza del modelo de regresión.

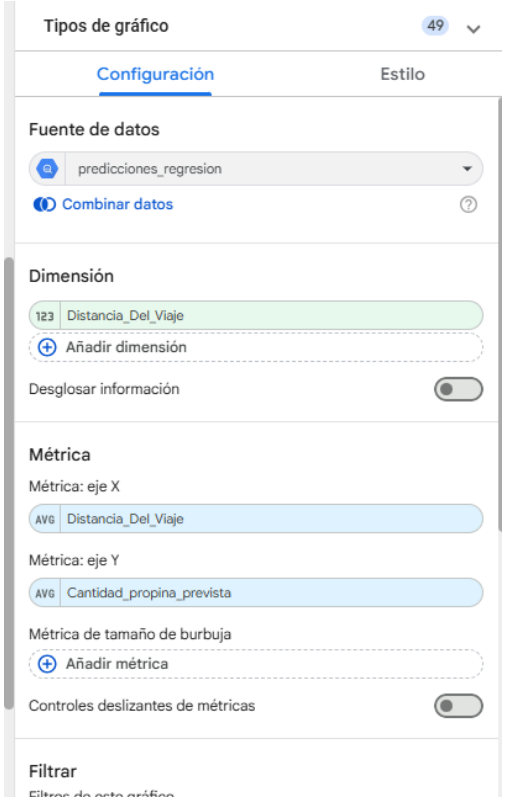

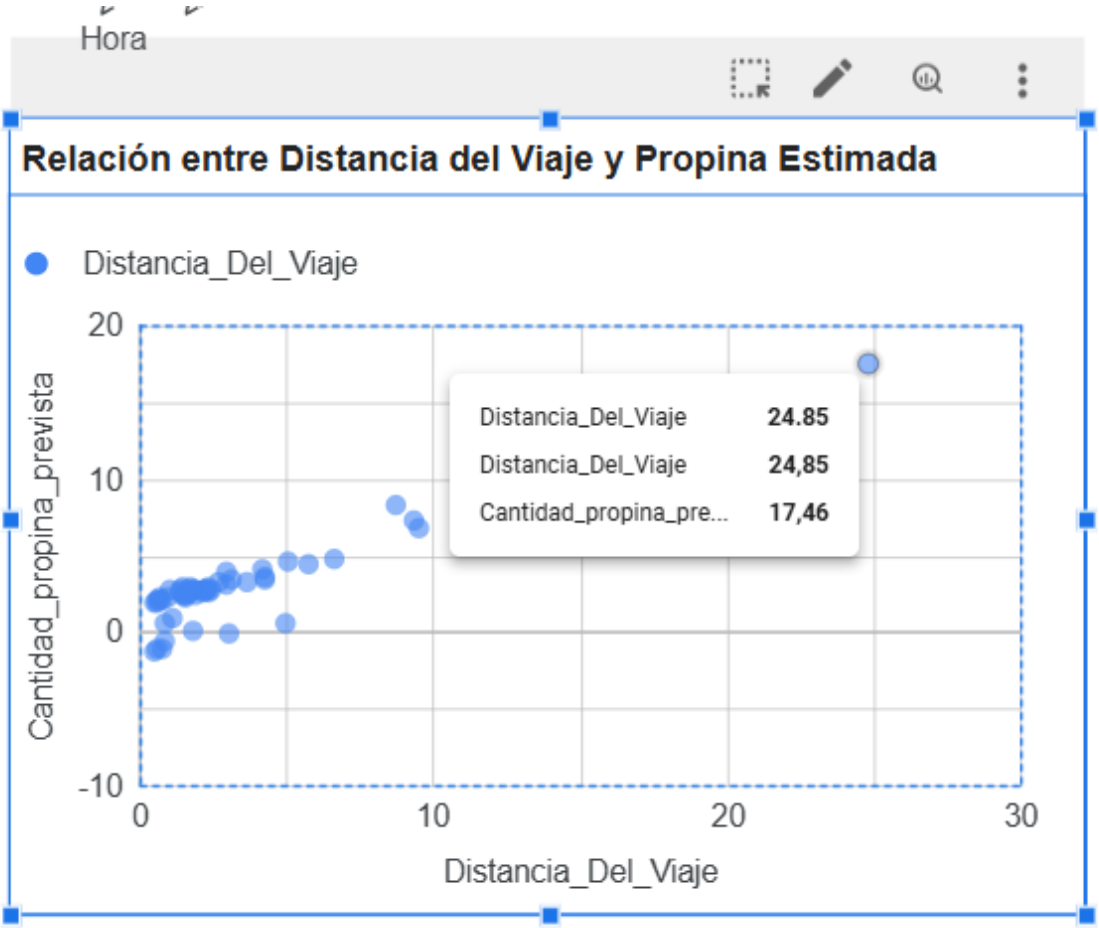

Conclusión técnica

El modelo identifica correctamente que la distancia es un factor influyente en el monto de propina.

GRÁFICA 2

Propina Promedio Estimada por Hora del Día

Objetivo

Analizar cómo varía la propina estimada según la hora del día.

PASOS PARA CREARLA

Insertar gráfico

Insertar → Gráfico → Barras

Configuración

Fuente de datos:
`predicciones_regresion`

Dimensión:

pickup_hour

Métrica:

AVG(predicted_tip_amount)

Ordenar

En configuración:
Ordenar por:

pickup_hour (ascendente)

Interpretación de la Gráfica 2

- Permite identificar horas con mayor propina promedio.
- Normalmente horas pico (mañana y tarde) presentan mayor valor.
- Horas nocturnas pueden mostrar menor promedio.
- Es útil para análisis operativo y estratégico.

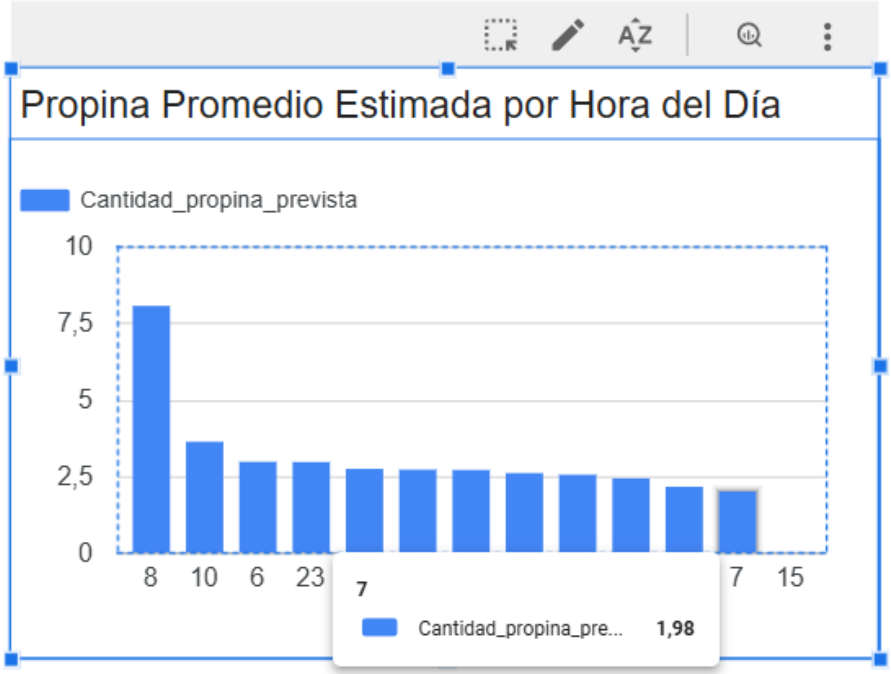
Propina Promedio Estimada por Hora del Día
Cantidad_propina_prevista
10
7,5
5
2,5
0
8
10
6
23
7
7
15
Cantidad_propina_pre...
1,98

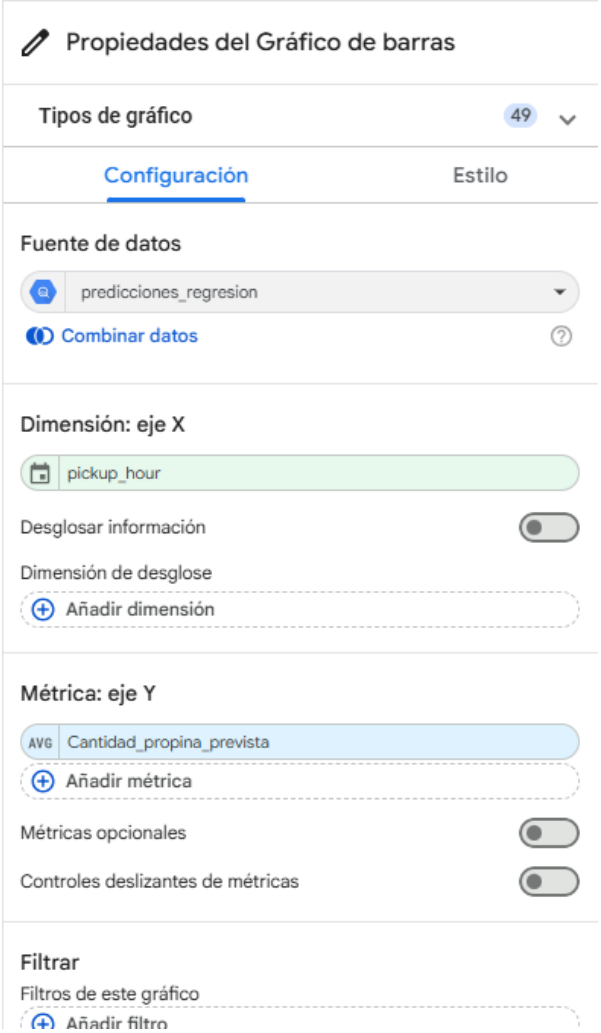
Propiedades del Gráfico de barras
Tipos de gráfico
49
Configuración
Estilo
Fuente de datos
predicciones_regresion
Combinar datos
Dimensión: eje X
pickup_hour
Desglosar información
Dimensión de desglose
Añadir dimensión
Métrica: eje Y
AVG
Cantidad_propina_prevista
Añadir métrica
Métricas opcionales
Controles deslizantes de métricas
Filtrar
Filtros de este gráfico
Añadir filtro

Resumen.

Se generaron visualizaciones a partir de la tabla predicciones_regresion, la cual contiene las predicciones del modelo de regresión. La primera gráfica evidencia una relación positiva entre la distancia del viaje y la propina estimada. La segunda gráfica muestra la variación del promedio de propina estimada a lo largo del día, permitiendo identificar patrones horarios relevantes

CONCLUSIONES

El proyecto permitió demostrar la importancia de aplicar técnicas de optimización y análisis en entornos de datos masivos. Mediante el uso de BigQuery, se logró procesar eficientemente grandes volúmenes de información y extraer patrones relevantes.

La implementación de modelos de Machine Learning permitió complementar el análisis exploratorio con capacidades predictivas, destacando la utilidad de herramientas como BigQuery ML en entornos de analítica avanzada.

Finalmente, el uso de visualizaciones facilitó la interpretación de resultados y la comunicación de hallazgos, consolidando un flujo completo de análisis de datos desde la extracción hasta la toma de decisiones.

BIBLIOGRAFÍA

Google Cloud. (2024). *BigQuery Documentation*

Google Cloud. *BigQuery ML Documentation*

NYC Taxi & Limousine Commission. *Trip Record Data*

Google. *Looker Studio Documentation*

Documentación ofi cial de BigQuery https://cloud.google.com/bigquery/docs

Documentación de BigQuery Public Datasets https://cloud.google.com/bigquery/public-data

Guías de particiones, clustering y Looker Studio https://cloud.google.com/bigquery/docs/partitioned-tables